Prvi deo projektnog zadatka - analiza baze podataka

Studenti: Sara Panić EE79/2018, Milan Stevanović EE205/2018

Ime baze sa linkom: [Birds 525 Species - Image Classification]

1. Definisati u 2-3 rečenice problem koji će se u projektu rešavati. (primer: Rešavaće se problem detekcije karcinoma dojke na osnovu analiza iz krvi. U pitanju je klasifikacioni problem sa 2 klase.) **– Projekat se bavi razvojem modela mašinskog učenja za prepoznavanje vrsta ptica na osnovu slika. Radi se o klasifikacionom problemu koji uključuje 525 različitih klasa, odnosno vrsta ptica.**

2. Koliko ima uzoraka u bazi? **– Baza sadrži ukupno 89 885 uzoraka, gde je 2625 uzoraka namenjeno za testiranje i validaciju, a 84 365 namenjeno za treniranje modela.**

3. Jednom rečenicom objasniti šta predstavlja jedan uzorak u konkretnoj bazi. – **Svaki uzorak u ovoj bazi predstavlja jednu sliku ptice, veličine 224x224 piksela, koja je klasifikovana u jednu od 525 vrsta.**

4. Koliko ima obeležja u bazi? **– S obzirom da su sve slike u formatu 224 x 224 x 3, broj numeričkih obeležja je 224 x 224 x 3 = 150 528, Kategoričkih obeležja ima 89 885.**

5. Navesti sva obeležja (jasnim imenom na srpskom ili opisno, nebitan je naziv u samoj bazi). **– Obeležja uključuju sve piksele slika, kao i metapodatke iz CSV datoteke (putanja do slike, ime vrste ptice, latinski naziv, skup podataka u kojem se slika nalazi, indeks klase).**

6. Koliko ima numeričkih obeležja? **– 224 x 224 x 3 = 150 528.**

7. Ako ima kategoričkih obeležja, navesti koje od njih ima najmanji broj kategorija i koje su, i navesti ono koje ima najveći broj kategorija i koliko ih je. **– Metapodaci kao što su ime ptice, latinski naziv, su kategorička obeležja. Obeležje sa najmanje kategorija je skup podataka (3 kategorije: trening, test, validacija), a ono sa najviše kategorija je ime vrste ptice ili latinski naziv (525 kategorija).**

8. Ako se rešava regresioni problem: navesti opseg, sr.vr. i medijanu obeležja koje će se predvidjati. Ako se rešava klasifikacioni problem: navesti procentualno koliko ima uzoraka u svakoj od klasa. **– Distribucija klasa u trening setu nije uniformna, najzastupljenije klase u trening setu su ptice 'Rufous Trepe', 'House Finch', 'D-Arnauds Barbet', 'Ovenbird' i 'Asian Green Bee Eater' sa brojem uzoraka od 263, 248, 233, 233, i 220 respektivno.**

9. Da li postoje obeležja u bazi koja smatraš da treba izbaciti iz baze? Koja su to i zašto smatraš da ih treba izbaciti? **– Potencijalno obeležje koje je moguće izbaciti iz baze je**

latinski naziv ptice koji neće služiti previše za klasifikaciju ptica s obzirom na postojanje obeležja sa imenom ptice.

10. Da li u bazi ima nedostajućih vrednosti? Ako ima, navesti za svako od obeležja koliko vrednosti mu procentualno nedostaje? **– U bazi nema nedostajućih vrednosti. Sve kolone („class id“, „filepaths“, „labels“, „data set“, „scientific name“) imaju popunjene vrednosti.**

11. Da li ima nevalidnih vrednosti u bazi? Ako ima, navesti za svako od obeležja koje su vrednosti nevalidne i zašto se smatraju nevalidnim. **– Nema nevalidnih vrednosti u bazi.**

12. Ako ima nedostajućih i/ili nevalidnih vrednosti u bazi, za svako od obeležja navesti kako će problem biti rešen. **– Nema nevalidnih vrednosti u bazi.**

13. Kada je završeno izbacivanje, dopuna, i drugo, navesti koliko je u sređenoj bazi ostalo uzoraka, a koliko obeležja. **– Baza je unapred očišćena od nevalidnih vrednosti i duplikata, s tim u vidu broj uzoraka i obeležja se ne menja.**

14. Da li neka od obeležja sadrže autlajere? Nabvesti koja obeležja ih sadrže. **– Statistička analiza „class id“ kolone ne pokazuje prisustvo očiglednih autlajera.**

15. Da li postoje parovi obeležja korelisani više od 0.7? Navesti takve parove obeležja. **– S obzirom da su svi numerički podaci ili pikseli slike ili „class id“ vrednosti, a „class id“ je diskretna numerička vrednost, analiza korelacije između ovih obeležja nije relevantna.**
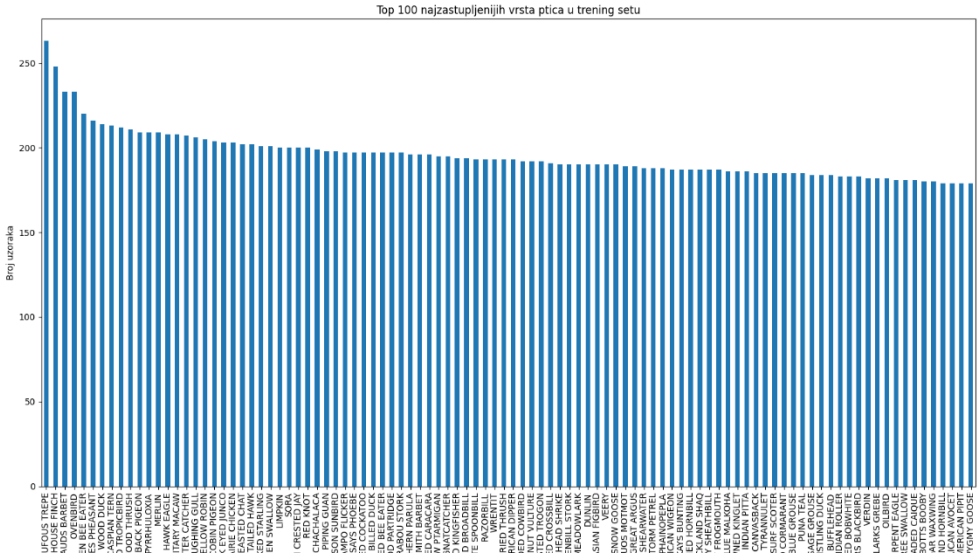
16. Ako se rešava klasifikacioni problem: iscrtavanjem histograma reći koje se obeležje izdvaja kao najdiskriminatornije (najbolje razdvaja klase)? Ako se rešava regresioni problem: utvrditi koliko je odstupanje raspodele varijable koja se predviđa od normalne raspodele dobijene korišćenjem uzoračke sr.vr. i standardne devijacije (asimetričnost i spljoštenost)? – **Zbog velikog broja klasa (525) histogram je bio teško čitiljiv i iskorišćeno je top 100 najzastupljenijih klasa za crtanje histograma.**